

Predicción de resultados de finales de ajedrez KR-vs-KP mediante aprendizaje supervisado*

Marlon Giraldo-Ramírez

Juan Felipe Santa

¹⁾Departamento de Ingeniería de Sistemas, Universidad de Antioquia, Medellín, Colombia.

Este artículo aborda la predicción del desenlace en el final de ajedrez *King-Rook vs King-Pawn* (KR-vs-KP) como tarea de clasificación binaria supervisada sobre el conjunto *kr-vs-kp* (OpenML ID 3). El objetivo es estimar, a partir de descriptores simbólicos completamente categóricos, si las blancas pueden forzar la victoria (*won*) o no (*nowin*). Se comparan dos familias de modelos representativas: Árbol de Decisión (CART), por su interpretabilidad y extracción de reglas, y SVM con kernel RBF, por su capacidad para modelar fronteras no lineales en alta dimensionalidad tras *one-hot encoding*. La evaluación se implementa mediante *pipelines* con validación estratificada (*k-fold*) y un conjunto de prueba retenido, reportando *accuracy* y *F1-macro* con intervalos de confianza, además de matriz de confusión para el mejor modelo. Los resultados muestran el compromiso clásico entre interpretabilidad y desempeño: CART facilita explicaciones explícitas de tipo regla, mientras que SVM tiende a ofrecer mayor equilibrio entre clases en el espacio expandido por la codificación. Se discuten amenazas a la validez y la vigencia de KR-vs-KP como banco de pruebas para métodos supervisados en datos categóricos.

Key Words: Machine Learning, Chess Endgames, Classification, Supervised Learning, OpenML

1. Descripción del problema

El presente proyecto aborda el problema de *predicción de resultados en posiciones finales de ajedrez del tipo King-Rook vs King-Pawn (KR vs KP)*, un escenario clásico en el estudio de finales. El objetivo es desarrollar un modelo que, a partir de un conjunto de características estratégicas derivadas del análisis humano, determine si las blancas pueden forzar la victoria o no. Este problema combina reglas deterministas con conceptos heurísticos, lo que lo convierte en un caso ideal para estudiar cómo los modelos de aprendizaje automático pueden aprender y reproducir conocimiento experto a partir de datos simbólicos.

1.1. Contexto y utilidad de una solución basada en ML

Los finales de ajedrez, aunque completamente definidos por las reglas del juego, presentan una complejidad combinatoria que hace inviable explorar exhaustivamente todas las posibles secuencias de jugadas. Por ello, los teóricos del ajedrez han desarrollado a lo largo del tiempo un conjunto de conceptos heurísticos que permiten valorar una posición: centralización del rey, actividad de la torre, control de columnas o proximidad del peón a la coronación, entre otros. El trabajo de Shapiro recopiló estos conceptos en forma estructurada, convirtiéndolos en variables simbólicas que describen configuraciones tácticas.

En este contexto, el uso de técnicas de aprendizaje automático resulta especialmente útil, pues permite aprender la relación entre estos conceptos estratégicos y el desenlace final sin necesidad de programar reglas explícitas o simular partidas. Así, el modelo puede inferir patrones de victoria directamente a partir de datos simbólicos, representando un puente entre la cognición humana y el razonamiento estadístico. Su utilidad radica no solo en la predicción de resul-

tados, sino en la capacidad de analizar qué combinaciones de factores estratégicos conducen a una victoria.

Utilidad de ML. Una solución de aprendizaje supervisado permite (i) generalizar desde ejemplos etiquetados a posiciones nuevas sin programar reglas explícitas ni realizar búsqueda de jugadas, (ii) operar como *oráculo* rápido para estudio/entrenamiento, y (iii) capturar interacciones no lineales entre descriptores simbólicos, manteniendo opciones de interpretabilidad (árboles) o máximo desempeño (SVM).

1.2. Composición de la base de datos

El conjunto de datos utilizado es el *KR vs KP Endgame (Shapiro)*, disponible en la plataforma OpenML (ID 3). Este dataset fue compilado a partir del libro *Chess Endgames: Knowledge and Patterns* de Shapiro, y contiene ejemplos etiquetados sobre si la posición es ganadora o no para las blancas.

- **Número de instancias:** 3,196 posiciones.
- **Número de variables:** 37 en total (36 predictoras y 1 variable objetivo).
- **Naturaleza de las características:** cada atributo corresponde a una abreviatura simbólica (por ejemplo, *r1mmx*, *wknck*, *bxqsq*, *katri*), que representa una propiedad estratégica de la posición, como la ubicación relativa de las piezas o el control posicional de columnas.
- **Variable objetivo:** *class*, con dos valores posibles: *won* y *nowin*.
- **Distribución de clases:** aproximadamente 52% ganadoras y 48% no ganadoras, lo que permite un entrenamiento estable sin necesidad de técnicas de balanceo.
- **Valores faltantes:** no se registran datos ausentes.
- **Codificación:** se empleará *one-hot encoding*, adecuada para variables categóricas nominales, generando vec-

tores binarios sin imponer relaciones ordinales artificiales.

Este conjunto de datos es especialmente valioso porque integra conocimiento experto humano en un formato legible por máquina, permitiendo comparar la efectividad de distintos algoritmos en la representación y aprendizaje de razonamiento simbólico.

1.3. Paradigma de aprendizaje y justificación

Dado que cada instancia se asocia con una etiqueta binaria que indica si la posición es ganadora o no, el problema se enmarca dentro del paradigma de *aprendizaje supervisado*, específicamente como una tarea de clasificación binaria simbólica. La función objetivo se define como:

$$f : X \rightarrow \{won, nowin\},$$

donde X representa el espacio de características semánticas derivadas de conceptos ajedrecísticos. El conjunto de datos puede caracterizarse como un dominio simbólico, discretizado, con ligera desbalance de clases y sin ruido perceptible.

Se seleccionan inicialmente dos modelos representativos:

1. **Árboles de Decisión (CART):** permiten extraer reglas interpretables que vinculan combinaciones de características con resultados. Facilitan la visualización de patrones estratégicos y la generación de explicaciones simbólicas del tipo “torre activa + rey centralizado \Rightarrow victoria”.
2. **Máquinas de Vectores de Soporte (SVM):** adecuadas para espacios de alta dimensionalidad tras la codificación *one-hot*. Su capacidad de usar funciones kernel permite modelar relaciones no lineales entre conceptos estratégicos.

El análisis comparativo de ambos modelos permitirá evaluar la capacidad de los algoritmos para capturar la lógica subyacente del conocimiento experto, analizando tanto desempeño predictivo como interpretabilidad.

2. Estado del arte

En los últimos años, diferentes investigaciones han explorado cómo las técnicas de aprendizaje automático pueden aplicarse al análisis de finales de ajedrez, abordando tanto la optimización del proceso experimental como la predicción directa de resultados. Entre ellas destacan los trabajos de Kühn et al. (2018) y Reddy et al. (2019), que representan dos perspectivas complementarias: el primero se centra en la automatización y comparación de modelos en plataformas abiertas, y el segundo en la aplicación directa de clasificadores a finales específicos del juego. A continuación, se resumen sus aportes más relevantes.

2.1. Kühn et al. (2018) — *Automatic Exploration of Machine Learning Experiments on OpenML*

Resumen general: este estudio propone un sistema automatizado para la exploración y evaluación de experimentos de aprendizaje en múltiples conjuntos de datos, incluyendo el

KR-vs-KP. Su objetivo principal es mejorar la reproducibilidad y la comparación entre algoritmos mediante flujos de trabajo estandarizados en la plataforma OpenML.

Configuración / paradigma: aprendizaje supervisado aplicado a la meta-experimentación y benchmarking. El trabajo ejecuta experimentos automatizados sobre 38 tareas de clasificación, incluyendo el dataset *KR-vs-KP* (OpenML ID 3).

Técnicas utilizadas: se evalúan múltiples algoritmos (*glmnet*, *rpart*, *kknn*, *svm*, *ranger*, *xgboost*) con amplias rejillas de hiperparámetros.

Validación y métricas: la validación se realiza mediante *k-fold cross-validation*, utilizando métricas de *accuracy* y *F1-score*.

Resultados: el estudio no busca optimizar un modelo específico, sino demostrar un marco reproducible para la comparación de algoritmos. Sus conclusiones resaltan la importancia de diseñar flujos de validación consistentes y de explorar múltiples familias de modelos, principios que este proyecto adopta.

2.2. Reddy et al. (IJRASET, 2019) — *Predicting Outcomes of Chess Endgames Using Machine Learning*

Resumen general: este trabajo aplica directamente distintos algoritmos de aprendizaje supervisado a finales de ajedrez, incluyendo el *KR-vs-KP*, con el fin de comparar su desempeño y determinar qué técnicas logran la mejor precisión en la predicción de resultados.

Configuración / paradigma: aprendizaje supervisado orientado a la clasificación de posiciones ganadoras o perdedoras.

Técnicas utilizadas: se comparan clasificadores como Regresión Logística, Árboles de Decisión, Bosques Aleatorios, SVM y Redes Neuronales.

Validación y métricas: el estudio aplica una partición 70/30 entre entrenamiento y prueba, y utiliza métricas de *accuracy*, sensibilidad y especificidad.

Resultados: los modelos SVM y Bosques Aleatorios alcanzan los mejores desempeños, con precisiones cercanas al 95%. No obstante, la falta de validación cruzada limita la generalización de los resultados. El trabajo demuestra la eficacia de los métodos supervisados en la representación de conocimiento simbólico en ajedrez y justifica la elección de los algoritmos considerados en este proyecto.

Referencias

References

- 1) T. Kühn, M. Vanschoren, B. Bischl, and G. Casalicchio, “Automatic Exploration of Machine Learning Experiments on OpenML,” *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2018, pp. 1–9.
- 2) P. Sharma, R. Saini, and A. Bhardwaj, “Predicting Outcomes of Chess Endgames Using Machine Learning,” *International Journal for Research in Applied Science and Engineering Technology (IJRASET)*, vol. 7, no. 5, 2019, pp. 364–369.